

Automated Machine Learning

프로세스 설계서

작성자 : 송창화

1. 프로세스 개요



데이터 읽어 들이기 (Data Read)	데이터 확인 (Data Confirm)	데이터 전처리 (Data Preprocessing)	모델 선택/학습 (Model Selection/Training)	모델 평가/확인 (Model Evaluation/Confirm)
<p>1. [신규] 버튼 (1) 파일 선택, 문서명-> [등록] (2) Excel Data -> DB 처리 (3) 컬럼유형, 최소값,최대값, 평균, 표준편차,분산 제1/2/3 사분위(Q1~3) 누락값수 계산 처리 (4) Boxplot Image 생성</p> <p>2. [선택] 버튼 (1) 데이터 업로드 결과 display</p> <p>3. [삭제] 버튼 (1) 해당 문서 삭제 처리</p>	<p>1. 문서목록 - [선택] 버튼 (1) 컬럼별 데이터 분석 결과 - 컬럼유형, 최소값,최대값, 평균, 표준편차,분산 제1/2/3 사분위(Q1~3) 누락값수 Display</p> <p>2. 컬럼별 데이터 분석 결과 - [선택] 버튼 (1) 데이터 분포(Boxplot) Image display (2) [이미지]를 클릭하면 이미지가 [확대]됨.</p>	<p>1. [목표변수 적용] 버튼 (1) 목표변수 선택 Check 처리</p> <p>2) [데이터 전처리 적용] 버튼 (1) 중복값 처리 (2) 결측값 처리 (3) 이상값 처리</p>	<p>1. [분류 모델] 버튼 (1) 그라디언트 부스팅(Gradient Boost) (2) 의사 결정 트리(Decision Tree) (3) Random Forest (4) SVM(Support Vector Machine) (5) 신경망(Neural Network)</p> <p>2. [군집 모델] 버튼 (1) K-평균 군집화 (K-means Clustering)</p> <p>3. 모델별 학습 처리 (1) Confusion Matrix(혼동/오차 행렬) (2) (신경망) 훈련 데이터 대 검증 데이터 손실 그래프 (3) ROC Curve (수신자 판단 곡선)</p>	

2. 기능 프로세스

2.1 데이터 읽어 들이기 (Data Read)

1

A	B	C	D	E	F	G	H	I	J	K	
1	Channel	Region	Fresh	Milk	Grocery	Frozen	Detergent	Delicassen	Sugar	Apple	y
2	2	3	705	980	9566	7561	214	2674	1338	4656	3174 no
3	2	3	705	980	9566	7561	1762	3286	1776	6008	2397 yes
4	2	3	683	800	7684	6441	3516	7834	2196	5404 no	
5	1	3	13265	1196	4221	6404	507	1788	2196	5404 no	
6	2	3	22615	5410	7195	3915	1777	5185	4470	2915 no	
7	2	3	9413	8259	5126	466	1798	1451	7259	766 yes	
8	2	3	12126	3199	6975	480	3140	545	4199	580 no	
9	2	3	7579	9423	10423	1967	3321	2568	3993	1659 yes	
10	1	3	3463	3648	6192	425	1716	750	3148	475 yes	
11	2	3	6006	11093	18881	1159	7425	2098	11023	1139 yes	

1. Excel 파일(CSV 포맷)을 업로드 한다.

데이터 읽어 들이기

신규 파일 업로드

파일
파일 선택 선택된 파일 없음
문서 명



문서 명	처리상태	등록일	선택	삭제
테스트 - 2022.11.21(01)	업로드	2022-11-21	<input checked="" type="button"/> 선택	<input type="button"/> 삭제

등록 닫기

2

automl_dataread.py

2. 업로드된 파일을 적용하여 Auto ML 관련 테이블을 생성한다.

(1) 데이터 상세 테이블(TB_AUTOML_TEXT) Insert 처리

- Header 데이터
- 실제 데이터

(2) 데이터 컬럼 상세 테이블(TB_AUTOML_COLUMN_INFO) Insert 처리

- 컬럼유형, 최소값, 최대값, 평균, 표준편차, 분산, 제1/2/3 사분위(Q1~3)
- 누락값수

(3) 데이터 마스터 테이블(TB_AUTOML_MASTER) Update 처리

- 처리상태 코드 : 업로드
- 업로드 파일 행 개수, 업로드 파일 행 개수

3

automl_dataconfirm.py

3. 데이터 상세 테이블(TB_AUTOML_TEXT)을 select하여 데이터 컬럼 이미지 테이블을 생성한다.

(1) Boxplot(상자 수염 그림) Image 생성

- Boxplot(상자 수염 그림) - 서버에 저장하기
- IMAGE_GUBUN(이미지 구분) : '02'

2.2 데이터 확인 (Data Confirm)

1

문서 명 처리상태

Total : 13

문서 명	처리상태	등록일	선택
테스트 - 2022.11.01(03)	업로드	2022-11-18	선택
테스트 - 2022.11.01(02)	업로드	2022-11-18	선택
테스트 - 2022.11.01(01)	업로드	2022-11-18	선택

<< < 1 2 > >>

1. 문서목록에서 [선택] 버튼을 클릭한다.

2

칼럼 개수 : 5
[컬럼별 분석 결과] [제1사분위(Q1)-25%의 위치, 제2사분위(Q2)-50%의 위치, 제3사분위(Q3)-75%의 위치]
데이터 확인

칼럼 명	칼럼 유형	사용여부	최소값	최대값	평균	표준편차	분산	25%	50%	75%	누적값 수	선택
공원명	문자형	Y									0	선택
육지면적	실수형	Y	65.34	483.02	216.38	118.50	14042.81	149.14	178.58	236.57	0	선택
답방객수	정수형	Y	851815.00	6439653.00	2012578.42	1706610.44	2912519178922.81	869313.25	1068332.50	2976096.50	0	선택
도시면적객수	정수형	Y	851815.00	6439653.00	2012578.42	1706610.44	2912519178922.81	869313.25	1068332.50	2976096.50	0	선택
y	문자형	Y									0	선택

<< < 1 > >>

2. '컬럼별 데이터 분석 결과' 목록에서 [선택] 버튼을 클릭한다.

- (1) 3.번 처리
(2) [데이터 확인] 버튼을 클릭하면 처리상태가 '데이터 확인'으로 변경된다.

3



3. 데이터 분포(Boxplot) Image display
- [이미지]를 클릭하면 이미지가 확대된다.

2.3 데이터 전처리 (Data Preprocessing)

1.

2.

3.

1. 문서목록에서 [선택] 버튼을 클릭한다.


2. ‘컬럼별 데이터 분석 결과’ 목록에서 [목표변수 선택] Check 처리한다.

- (1) [목표변수 적용] 버튼을 클릭한다.
– 처리상태가 ‘데이터 전처리’로 변경된다.

3. [데이터 전처리] 구분별로 제거 여부, 사용 여부를 선택한다.

- (1) 중복값 처리
- (2) 결측값 처리
- (3) 이상값 처리

2.4 모델 선택/학습 (Model Selection/Training)



1. 문서목록에서 [선택] 버튼을 클릭한다.

2. 학습할 [분류 모델] / [군집 모델]을 클릭한다.

(1) 분류 모델

- 그레이디언트 부스팅(Gradient Boost)
- 의사 결정 트리(Decision Tree)
- Random Forest
- SVM(Support Vector Machine)
- 신경망(Neural Network)

(2) 군집 모델 : K-평균 군집화(K-means Clustering)

3. [분류 모델] / [군집 모델]을 학습하시겠습니까? → [예]를 클릭한 경우

- (1) 데이터 컬럼 상세 테이블(TB_AUTOML_COLUMN_INFO) select
- (2) 데이터 전처리(Data Preprocessing) – 목표변수 활용
 - 변수 정의
 - 범주형 데이터를 숫자형 데이터로 전환
 - 범주형 데이터와 숫자형 데이터 결합
 - 모든 특징의 이름 리스트 처리
- (3) 데이터 분할 – train_test_split
- (4) 알고리즘 선택
- (5) 학습, 예측
- (6) 학습 결과 테이블(TB_AUTOML_TRAINING_RESULT) 처리
- (7) ROC Curve(수신자 판단 곡선) 처리
- (8) Confusion Matrix(혼동/오차 행렬) 처리
- (9) (신경망) 훈련 데이터 대 검증 데이터 손실 그래프 처리
- (10) 처리상태 ‘모델 학습’으로 변경 처리


4

■ Total : 5 모델 학습 목록


※ 정밀도(Precision) : 모델이 True라고 분류한 것 중에서 실제 True인 것의 비율
 ※ 민감도(Sensitivity) : 실제 True인 것 속에서 모델이 True라고 예측한 것의 비율
 ※ F1-score : 정밀도와 민감도의 조화평균 $> 2 * (\text{정밀도} * \text{민감도}) / (\text{정밀도} + \text{민감도})$

학습 구분	정밀도	민감도	F1-score	학습일자	학습횟수	선택
Gradient Boost	0.5	0.5	0.5	2022-11-17	1	<button>선택</button>
의사결정트리	0.4	0.4	0.4	2022-11-17	1	<button>선택</button>
Random Forest	0.4	0.4	0.4	2022-11-17	1	<button>선택</button>
SVM	0.4	0.4	0.4	2022-11-17	1	<button>선택</button>
신경망	0.25	0.25	0.25	2022-11-17	1	<button>선택</button>

5



■ ROC Curve ※ 특이도(Specificity) : 실제 진단결과가 음성 중에 음성이라고 맞춘 비율
 ※ (수신자 판단 곡선) 모델의 효율성을 민감도와 특이도를 이용하여 그래프로 나타낸 것



5. [모델 학습] 처리 후, '모델 학습 목록'에 학습한 데이터가 나타난다.

- (1) 학습구분, 정밀도, 민감도, F1-score, 학습일자, 학습횟수
- (2) [선택] 버튼을 클릭하면 6. 학습 결과 Image가 나타난다.

6. 학습 결과 만들어진 Image

- (1) Confusion Matrix (혼동 / 오차 행렬)
 - 학습을 통한 예측성능을 측정하기 위해 예측 값과 실제 값을 비교하기 위한 표
- (2) ROC Curve (수신자 판단 곡선)
 - 모델의 효율성을 민감도와 특이도를 이용하여 그래프로 나타낸 것

2.5 모델 평가/확정 (Model Evaluation/Confirm)

1

Total : 22				조회
문서 명	처리상태	등록일	선택	
테스트 - 2022.11.17 (15개)	모델 학습	2022-11-17	<button>선택</button>	
테스트 - 2022.11.17 (14개)	모델 학습	2022-11-17	<button>선택</button>	
테스트 - 2022.11.17 (13개)	모델 학습	2022-11-17	<button>선택</button>	

1. 문서목록에서 [선택] 버튼을 클릭한다.



2

Total : 5 모델 학습 목록								
학습 구분	정밀도	민감도	F1-score	학습일자	학습횟수	확정일자	선택	확정
Gradient Boost	0.5	0.5	0.5	2022-11-17	1		<button>선택</button>	<button>확정</button>
의사결정트리	0.4	0.4	0.4	2022-11-17	1		<button>선택</button>	<button>확정</button>
Random Forest	0.4	0.4	0.4	2022-11-17	1		<button>선택</button>	<button>확정</button>
SVM	0.4	0.4	0.4	2022-11-17	1		<button>선택</button>	<button>확정</button>
신경망	0.25	0.25	0.25	2022-11-17	1		<button>선택</button>	<button>확정</button>

2. [확정] 버튼을 클릭한다..

- (1) 확정일자
- (2) 데이터 마스터 테이블(TB_AUTOML_MASTER) Update 처리
– 처리상태 코드 : 모델 확정

EasyOCR을 적용한 OCR Solution 개발

프로세스 흐름도

작성자 : 송창화

1. 프로세스 개요



1. 대상 : 사용자가 학습대상으로 선택한 글자이미지
2. 주요학습정보 : 글자이미지 파일과 해당 글자 정보
3. 처리개요 : EasyOCR로 통해 이미지 안에 있는 글자를 인식하고 인식된 글자를 다시 보정한 후 해당 이미지 글자를 학습시키므로써 글자 인식률을 높여가도록 한다.

■ 실행방법

- 1) Windows 실행 > CMD 수행
- 2) 학습
 - 2-1) CD C:\dev_project\project_ocr\training
 - 2-2) project_ocr_training.bat (배치실행 파일 : 매일 오전 1시에 자동 실행)


2. 기능 프로세스

2.1 문서 인식 및 추출, 학습

1



1. 인식할 이미지 또는 PDF 파일을 업로드 한다.



신규 파일 업로드

파일

[파일 선택] 선택된 파일 없음

상호(명칭)



순번	파일명	상호명	처리상태	선택	삭제
220616000000004	2page.pdf	테스트 상호2	완료		

[등록] [닫기]

2


project_ocr.py

2. 업로드된 파일을 EasyOCR 프로그램을 통해 문자 인식 및 추출 한다.
이때 EasyOCR는 이미 학습된 학습모델을 사용한다.

```
ocr_reader = easyocr.Reader(['en', 'ko'], gpu=True,  
                            model_storage_directory=model_storage_dir,  
                            user_network_directory=user_network_dir,  
                            recog_network=recog_network)
```

```
model_storage_directory = C:\dev_project\project_ocr\training\model  
user_networ_directory = C:\dev_project\projecte_ocr\training\user_network  
recog_network = custom (지정한 모델파일이름)
```

6



3

project_ocr.py

3. 인식된 글자이미지와 해당 글자를 찾아 박싱처리하며 각각의 글자이미지와 해당 글자를 DB에 저장한다.

TB_OCR_DOC_TEXT

TEXT_IMAGE_PATH	TEXT_NM	SCORE
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_1.png	신고번호	0.99996
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_2.png	제 2021-00058호	0.79328
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_3.png	사업장 폐기물 배출자 신고증 명서	0.51762
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_4.png	[폐기물관리법 시행규칙] 제18조제2항제1호 및	0.35470
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_5.png	제2호에 해당하는	0.67710
C:\dev\project\aiblue_ocr\textimagefile\220529000000010_01_6.png	경우)	0.99315

4

인식/추출 검증

4. 인식 및 추출된 이미지와 글자를 확인한 후 잘못 인식된 글자에 대한 글자를 보정하여 저장한다.


OCR 인식/추출 관리

제2호에 해당하는	제2호에 해당하는	0.12	제2호에 해당하는
디엘이언씨 (주)	디엘이언씨(주)	0.82	디엘이엔씨(주)

5

학습대상 선정

5. 인식 및 추출된 글자중 추가 학습이 필요한 대상을 선정한다.



선택	인식 이미지	추출 글자	Score	김종 글자
<input checked="" type="checkbox"/>	신고 번호	신고번호	0.99997	
<input type="checkbox"/>	제 20210617호	제 20210617호	0.84961	
<input checked="" type="checkbox"/>	건설폐기물	건설폐기물	0.62347	

TB_OCR_DOC_TEXT

TEXT_NM	SCORE	TEXT_UPDT_NM	TEXT_TRAINING_YN
신고를	0.58454	NULL	Y
하여울을 증명합니다	0.39516	하였을을 증명합니다.	Y
2027년 08월 05일	0.93767	2021년 08년 05일	Y
서울특별시 강남구	0.47139	NULL	N

6

project_ocr_training.py

6. 사전학습모델을 기반으로 추가학습 대상을 일배치로 학습한다.

6.1. 학습대상 데이터의 글자이미지와 글자 정보를 가져온다.(신규 학습대상 및 기존 학습건 모두 가져온다)

```
SELECT * FROM TB_OCR_DOC_TEXT WHERE (TEXT_TRAINING_YN = 'Y' OR TEXT_TRAINING_SCORE > 0)
```

```
for idx, doc in enumerate(doc_text_list):
    train_image_path = doc['TEXT_IMAGE_PATH']
    train_image_nm = doc['TEXT_IMAGE_PATH'].split('\\')[-1].split('.')
    image_ext = train_image_nm[-1]
    text_upd_nm = ''
    if doc['TEXT_UPDT_NM'] is not None and doc['TEXT_UPDT_NM'] != '':
        text_upd_nm = doc['TEXT_UPDT_NM']
    else:
        text_upd_nm = doc['TEXT_NM']

    shutil.copyfile(train_image_path, step1_file_path + '\\train\\' + text_upd_nm + '_' + str(idx) + '.' + image_ext)
```

6.2. 학습대상 데이터가 너무 작은 경우 필요시 학습을 위한 글자이미지를 생성하여 학습에 이용하도록 한다.

```
SELECT * FROM TB_OCR_TRAIN_TEXT WHERE DEL_YN = 'N'
```

```
make_image_lib    = default_path + '\\\\TextRecognitionDataGenerator\\\\trdg\\\\run.py'
train_text_path  = learn_image_path + '\\\\train_text.txt'
make_image_train = "python {run} -c {count} -l ko -i {text} --output_dir {output}" \
.format(run=make_image_lib, count=data_count['train'], text=train_text_path, output=os.path.join(step1_file_path, 'train'))
```

6.3. 빠른 학습을 위한 학습 데이터셋을 생성한다.

```
convert_image_lib = default_path + '\\\\TRDG2DTRB\\\\convert.py'
make_lmdb_lib     = default_path + '\\\\deepTextRecognitionBenchmark\\\\create_lmdb_dataset.py'
convert_image_train = "python {convert} --input_path {input}\\\\train --output_path {output}\\\\train" \
.format(convert=convert_image_lib, input=step1_file_path, output=step2_file_path)
make_lmdb_train   = "python {lmdb} --inputPath {input}\\\\train --gtFile {input}\\\\train\\\\gt.txt --outputPath {output}\\\\train" \
.format(lmdb=make_lmdb_lib, input=step2_file_path, output=step3_file_path)
```

C:\dev_project\project_ocr\training\learning_image\3\train\ □ data.mdb 1,048,576KB
□ lock.mdb 8KB

6.4. 학습데이터셋으로 글자인식 학습을 실행한다. (학습시 easyocr에서 제공하는 사전학습모델 사용)

```
model_train_lib    = default_path + '\\\\deepTextRecognitionBenchmark\\\\train.py'
pretrained_model   = default_path + '\\\\EasyOCR\\\\pre_trained_models\\\\korean_g2.pth'
exp_name           = 'aiblue_ocr'
learning_model     = os.path.join('saved_models', exp_name)
number_of_iteration = 3000
interval_for_valid = 100
batch_size          = 32
model_train = 'python {train} \\' \
               '--exp_name {exp_name} \\' \
               '--train_data {input}\\\\train \\' \
               '--valid_data {input}\\\\valid \\' \
               '--select_data / \\' \
               '--batch_ratio 1 \\' \
               '--Transformation None \\' \
               '--FeatureExtraction VGG \\' \
               '--SequenceModeling BiLSTM \\' \
               '--Prediction CTC \\' \
               '--input_channel 1 \\' \
               '--output_channel 256 \\' \
               '--hidden_size 256 \\' \
               '--batch_max_length {batch_max_length} \\' \
               '--saved_model {saved_model} \\' \
               '--FT \\' \
               '--workers 0 \\' \
               '--data_filtering_off \\' \
               '--num_iter {num_iter} \\' \
               '--valInterval {valInterval} \\' \
               '--batch_size {batch_size}' .format(train=model_train_lib, \
                                         exp_name=exp_name, \
                                         input=step3_file_path, \
                                         num_iter=number_of_iteration, \
                                         valInterval=interval_for_valid, \
                                         batch_size=batch_size, \
                                         batch_max_length=batch_max_length, \
                                         saved_model=pretrained_model)
```

<https://www.jaided.ai/easyocr/modelhub/>

Model Hub

2nd Generation Models

english_g2

latin_g2

zh_sim_g2

japanese_g2

korean_g2

telugu_g2

kannada_q2

6.5. 학습된 학습모델을 신규 문서 인식 및 추출에 사용할 수 있도록 해당 폴더에 복사한다.

```
model_storage_dir = default_path + '\\\\model'
user_network_dir = default_path + '\\\\user_network'
recog_network = 'custom'
learn_image_path = default_path + '\\\\learning_image'
shutil.copyfile(learning_model + '\\\\best_accuracy.pth', model_storage_dir + '\\\\' + recog_network +'.pth')
```

6.6. 학습 대상인 이미지에 대해 학습된 모델로 다시 인식하고 해당 결과를 DB에 업데이트 한다.

```
SELECT * FROM TB_OCR_DOC_TEXT WHERE TEXT_TRAINING_YN = 'Y' AND TEXT_TRAINING_NM IS NULL
```

```
model_storage_dir = default_path + '\\\\model'
user_network_dir = default_path + '\\\\user_network'
recog_network = 'custom'
ocr_reader = easyocr.Reader(['en', 'ko'], gpu=True,
                            model_storage_directory=model_storage_dir,
                            user_network_directory=user_network_dir,recog_network=recog_network)
for idx, doc in enumerate(text_training_list):
    src_image = doc['TEXT_IMAGE_PATH']
    result = ocr_reader.readtext(src_image
                                , detail='wordbeamsearch'
                                , paragraph=False
                                , min_size=5)
```

2

project_ocr.py